Цель работы

Исследовать способы автоматического построения регрессионных моделей как суперпозиций экспертно-заданных функций.
Задачи:

1. Предложить метод индуктивного порождения суперпаозиций, исследовать его свойства
2. Предложить метод поиска изоморфных структур суперпозиций.
3. Предложить метод модификации и упрощения суперпозиций.
4. Применить предложенные методы для автоматического построения экспертно-интерпретируемых моделей.

Постановка задачи регрессии

Задано множество моделей $\mathfrak{F}$:

$$\mathfrak{F} = f_1, \ldots, f_k$$

$$f : \mathbb{X} \times \mathbb{W} \to \mathbb{Y}$$

$$x \in \mathbb{X} \subseteq \mathbb{R}^n$$

Требуется найти модель f, минимизирующую значение функции ошибки $S(f)$ при ограничении на структурную сложность $C(f)$:

$$S(f_0) \to \min$$

$$C(f_0) < C_0$$

Внутренний и внешний критерии качества

Наряду с внешним критерием качества S

$$S(\mathbf{w}|D, f) = ||f(\mathbf{x}, \mathbf{w}) - y|| = \|\mathbf{y} - f\|^2.$$

Могут также штрафоваться большие значения параметров в соответствии с внутренним критерием.

$$S(\mathbf{w}) = \frac{1}{2}\beta\|\mathbf{y} - f\|^2 + \frac{1}{2}\alpha\|\hat{\mathbf{w}} - \mathbf{w}\|^2.$$

Модели как суперпозиции

Экспертно задано множество G порождающих функций $g(\mathbf{w}, \mathbf{x})$.
Для g_i определены области аргументов $\mathbf{w} \in \mathbb{R}^m, \mathbf{x} \in \mathbb{R}^n$ и значений $g_i(x) \in \mathbb{R}^1$.
Множество G пополняется функциями $\mathrm{id}(\mathbf{x})$ и const.
Искомая модель f будет искаться среди множества $\mathfrak{F}$ суперпозиций функций $g \in G$.

Допустимые суперпозиции

$$f = (g_1 \circ \ldots \circ g_V)(\mathbf{x})$$

Определение

Допустимыми называют суперпозиции, удовлетворяющие следующим требованиям

- *Элементами s_i суперпозици f могут являться только порождающие функции g_j и свободные переменные x_i.*
- *Количество аргументов элемента суперпозиции s_i равно арности соответствующей ему функции g_j.*
- *Порядок аргументов элемента s_i суперпозиции f соотвествует порядку аргументов соответствующей функции g_j.*
- *Для элемента s_i, аргументом которого является элемент s_j, для соответствующих порождающих функций $dom(g_i) \supset cod(g_j)$;*

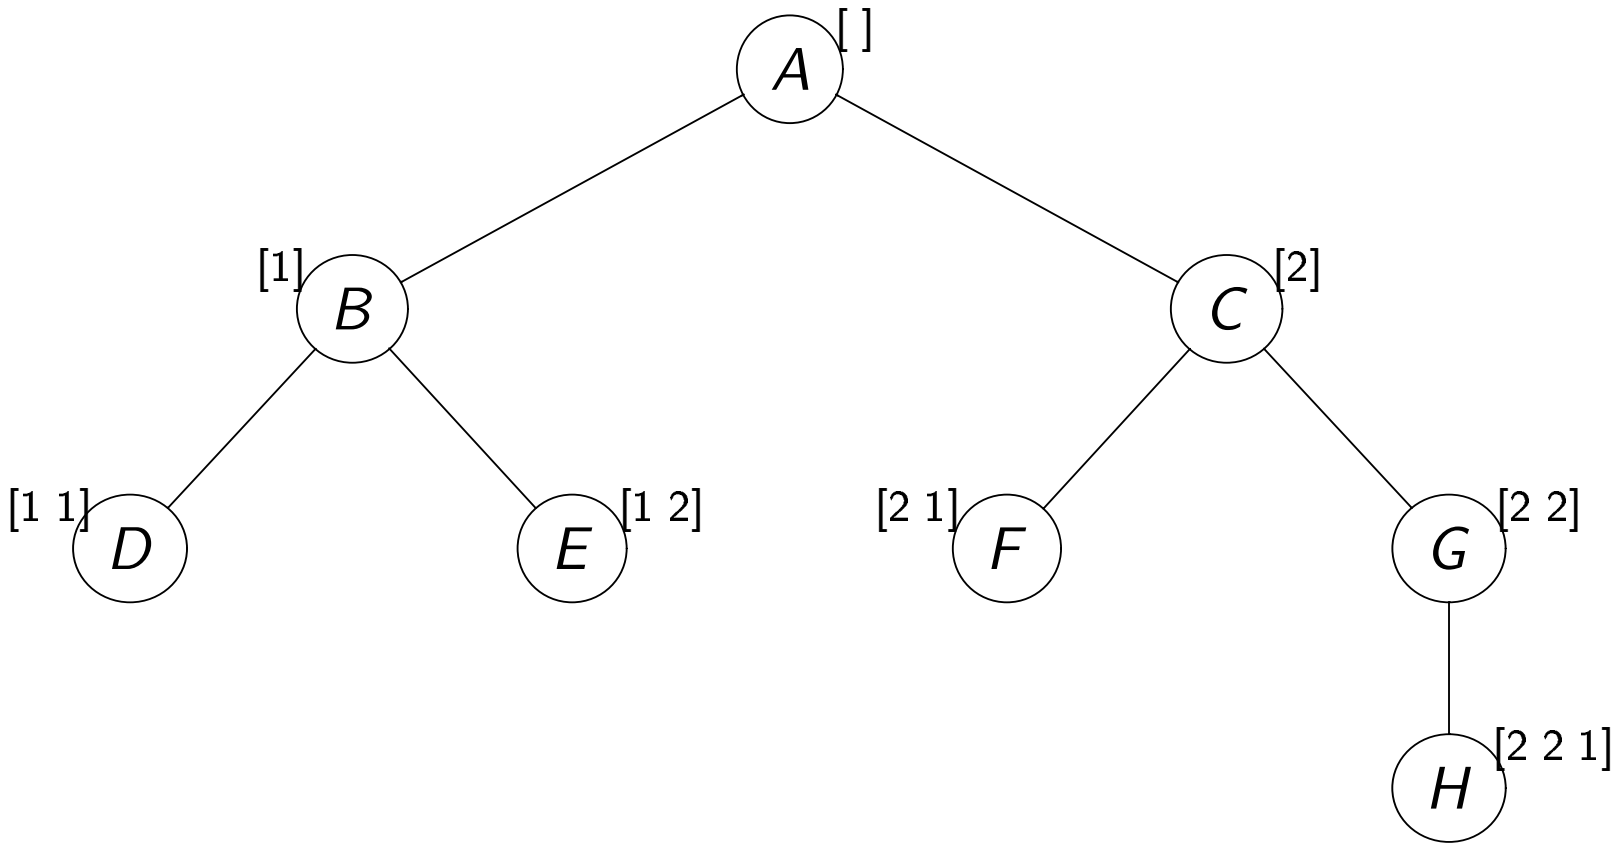
Представление суперпозиций в виде деревьев

Каждой суперпозиции f однозначно соответствует дерево Γ_f:

- В вершинах v_i дерева Γ_f находятся соответствующие функции g_j.
- Число дочерних вершин у v_i равно арности соответствующей функции g_j.
- Порядок дочерних вершин v_i соотвествует порядку аргументов функции g_j.
- Листьями дерева Γ_f являются x_i или const.

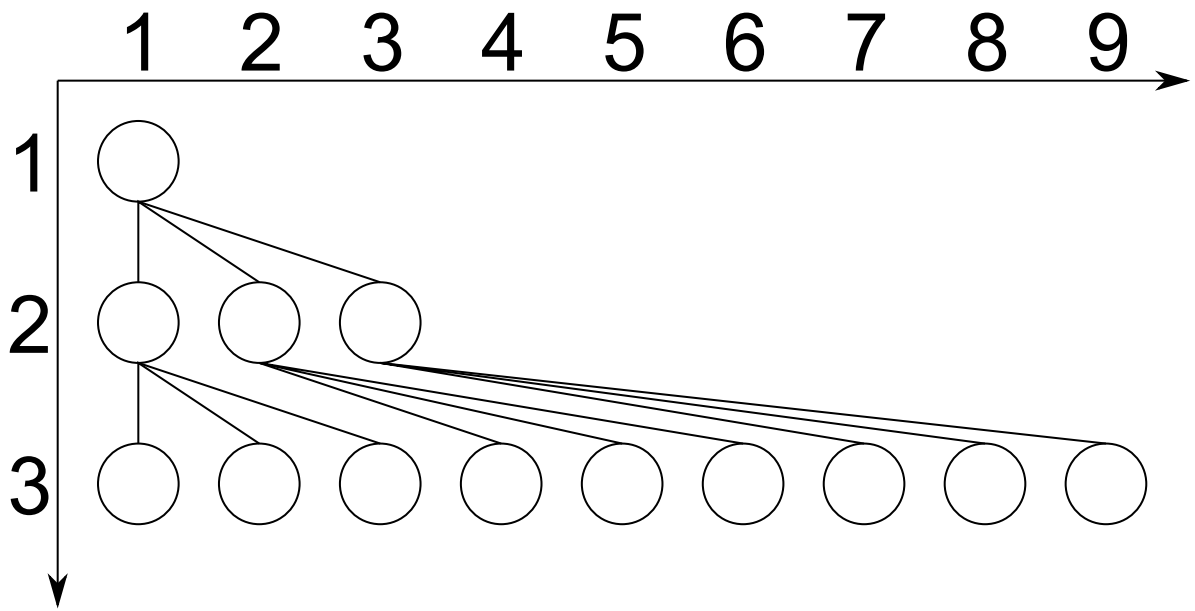
Система координат на деревьях

Естественным образом каждой вершине может быть сопоставлена координатная строка.



Прямоугольная система координат

Наиболее удобным способом задания координат является прямоугольная система, в которой ограничена арность вершин $a_{\max}$.



Расстояние между моделями

Определение

Дерево $\Gamma'(V')$ называется поддеревом дерева $\Gamma(V)$, если его множество вершин V' является подмножеством множества V.

Определение

Два дерева Γ_1 и Γ_2 называются изоморфными, если между их множествами вершин существует взаимно однозначное отображение, сохраняющее метки вершин.

Определение

Дерево Γ_0 называется общим поддеревом деревьев Γ_1 и Γ_2, если в них существуют поддеревья Γ'_1 и Γ'_2, изоморфные дереву Γ_0.

Расстояние между моделями

Определение

Общее поддерево двух деревьев называется наибольшим, если в нем содержится наибольшее число вершин среди других общих поддеревьев. Наибольшее поддерево деревьев $\Gamma_i(V_i)$ *и* $\Gamma_j(V_j)$ *обозначается как* $\Gamma_{ij}(V_{ij})$. *Символом* p *будет обозначаться количество элементов в множестве* V: $|V_i| = p_i$, $|V_j| = p_j$, $|V_{ij}| = p_{ij}$.

Рассмотрим абсолютную функцию расстояния r между Γ_i и Γ_j, зависящую от их размеров и наибольшего общего подграфа,

$$r_{ij} = p_i + p_j - p_{ij},$$

Доказательство аксиом метрики

Рассмотрим неравенство треугольника. Пусть даны графы Γ_1, Γ_2 и Γ_3. Необходимо доказать неравенство:

$$r_{12} + r_{23} \geq r_{13},$$

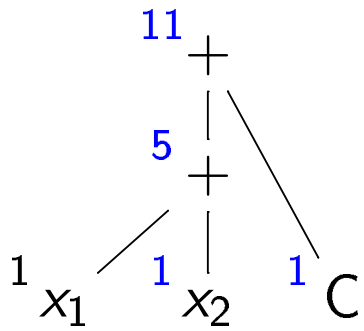
$$p_1 + p_2 - 2p_{12} + p_2 + p_3 - 2p_{23} \geq p_1 + p_3 - 2p_{13},$$

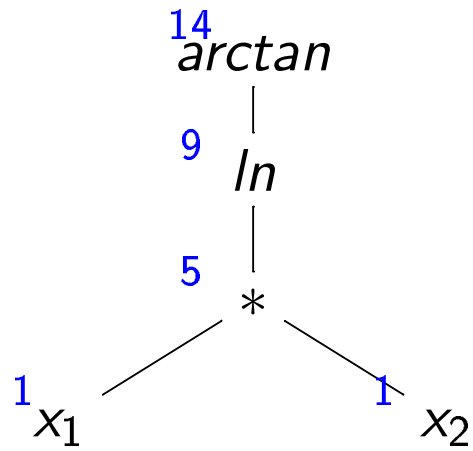
$$p_2 - p_{12} - p_{23} + p_{13} \geq 0.$$

Сложность суперпозиции

Описание суперпозиции f, представленной в виде дерева Г, определяется следующими параметрами.

1. Число вершин v_i в дереве Г.
2. Количество порождающих функций g_i, не являющихся терминальными вершинами x_i.





Сложность суперпозиции

Сложность суперпозиции равна f сложности корня v_0 и определяется индуктивно с помощью следующей процедуры:

1. Сложность C суперпозиции, дерево которой представляет собой одну вершину, соответствующую константной порождающей функции, равна 0:

$$C(\text{const}) = 0.$$

2. Сложность C суперпозиции f, дерево Γ которой представляет собой одну свободную переменную x_i равна 1:

$$C(x_i) = 1.$$

3. Сложность суперпозиции $g_i(f)$, где $C(f) = K$, а g_i - порождающая функция, равна сумме количества элементов в $g_i(f)$ и сложности f:

$$C(g_i(f)) = C(f) + |g_i(f)|$$

Построение всех допустимых суперпозиций

Перед первым шагом построим начальное значения множества моделей $\mathcal{F}_0$:

$$\mathcal{F}_0 = \{X, C\},$$

На каждом шаге для $\mathcal{F}_i$ построим множество U_i из суперпозиций, полученных при применении функций $g_i \in G$ к элементам $f_j \in \mathcal{F}_{i-1}$:

$$U_i = \{g_i(f_{j_1}, \dots f_{j_k}), \mid g_i \in G_u, f \in \mathcal{F}_{i-1}\}.$$

Тогда множество F_i

$$\mathcal{F}_i = \mathcal{F}_{i-1} \cup U_i.$$

Построение всех допустимых суперпозиций

Theorem

При данном способе порождения будут построены все конечные допустимые суперпозиции.

База индукции: деревья высоты 1 порождаются на нулевом шаге алгоритма.
Индукционный переход: Порождаются все суперпозиции $\mathcal{F}_h$ с деревьями Γ высоты h. Рассмотрим f_{h+1} с дерево Γ_{h+1}. Для каждого поддерева корня Γ_{h+1} утверждение теоремы верно. Тогда на некотором шаге алгоритма в множестве U_{p+1} будет элемент, где g_j — функция корня Γ_{h+1}, аргументы — его потомки.

Количество возможных суперпозиций

Пусть в множестве порождающих функций G содержится l_p функций максимальной арности $p > 1$, и имеется $n > 1$ независимых переменных.
Справедлива следующая оценка количества суперпозиций, порожденных алгоритмом $\mathfrak{A}$ после k-ой итерации:

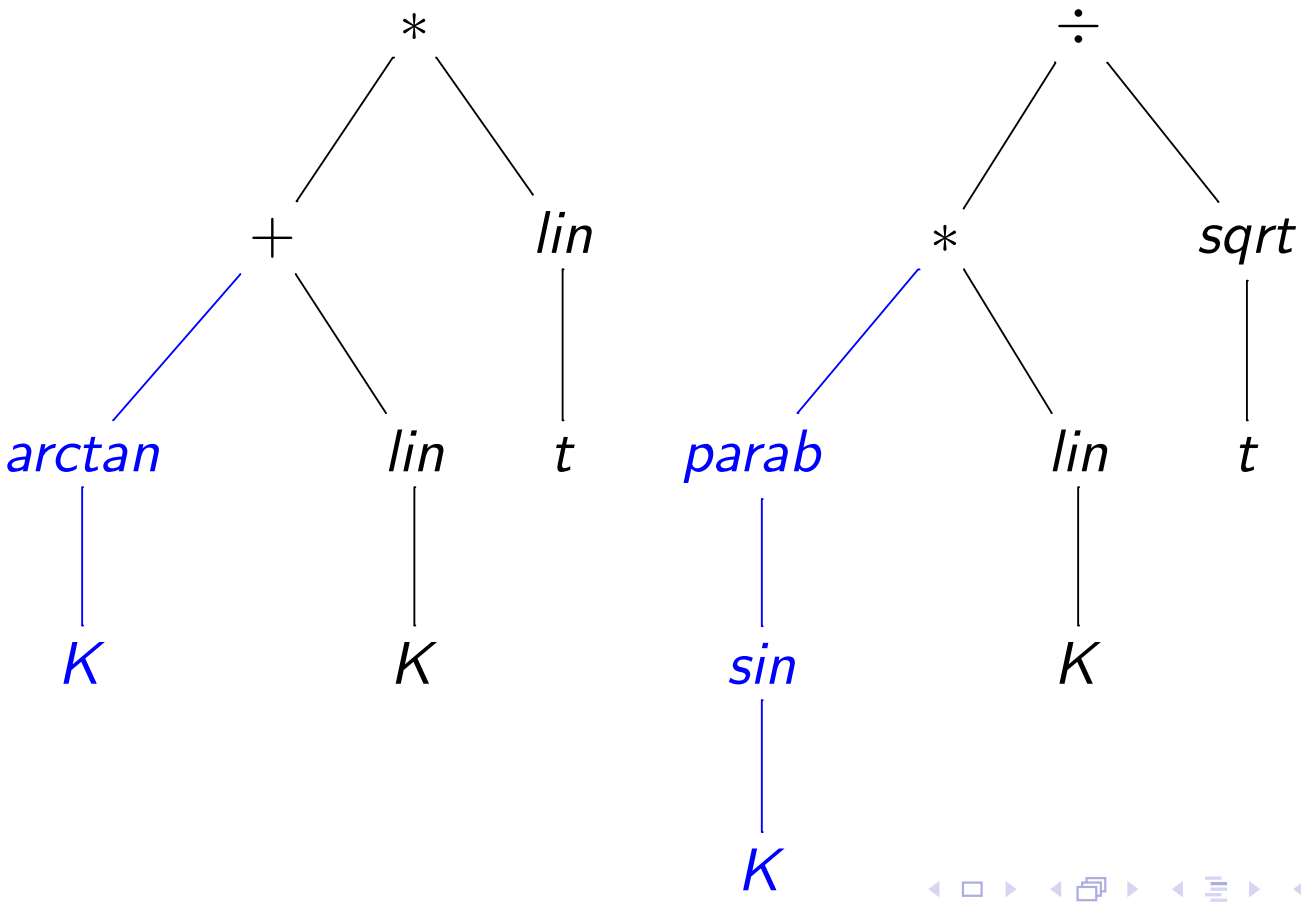
$$|\mathcal{F}_k| = \mathcal{O}(l_p^{(p^k-1)/(p-1)} n^{p^k}).$$

Алгоритм последовательного порождения моделей

0. Экспертно задается множество исходных моделей.
1. Выполняется обмен поддеревьями.
2. Выполняется модфикация суперпозиции
3. В соответствии с критерием качества отбираются лучшие модели и далее происходит следующая итерация процесса.

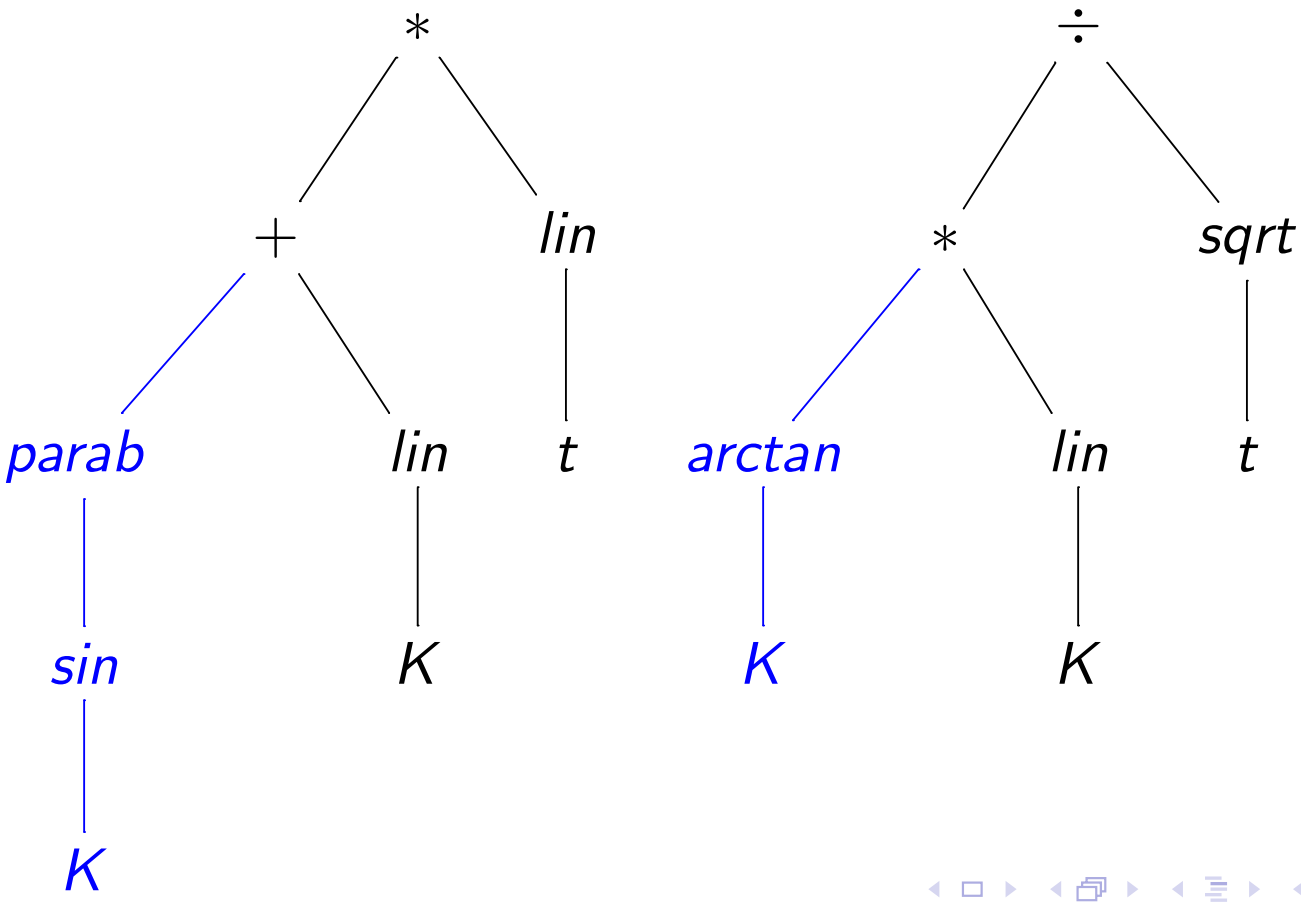
Алгоритм последовательного порождения моделей

1. Выполняется обмен поддеревьями:
   1. случайно выбирается пара суперпозиций f_i и f_j.
   2. в деревьях Γ_i и Γ_j выбираются вершины v_i и v_j
   3. порождаются новые модели f_i' и f_j' путем обмена поддеревьями с корнями в выбранных вершинах.



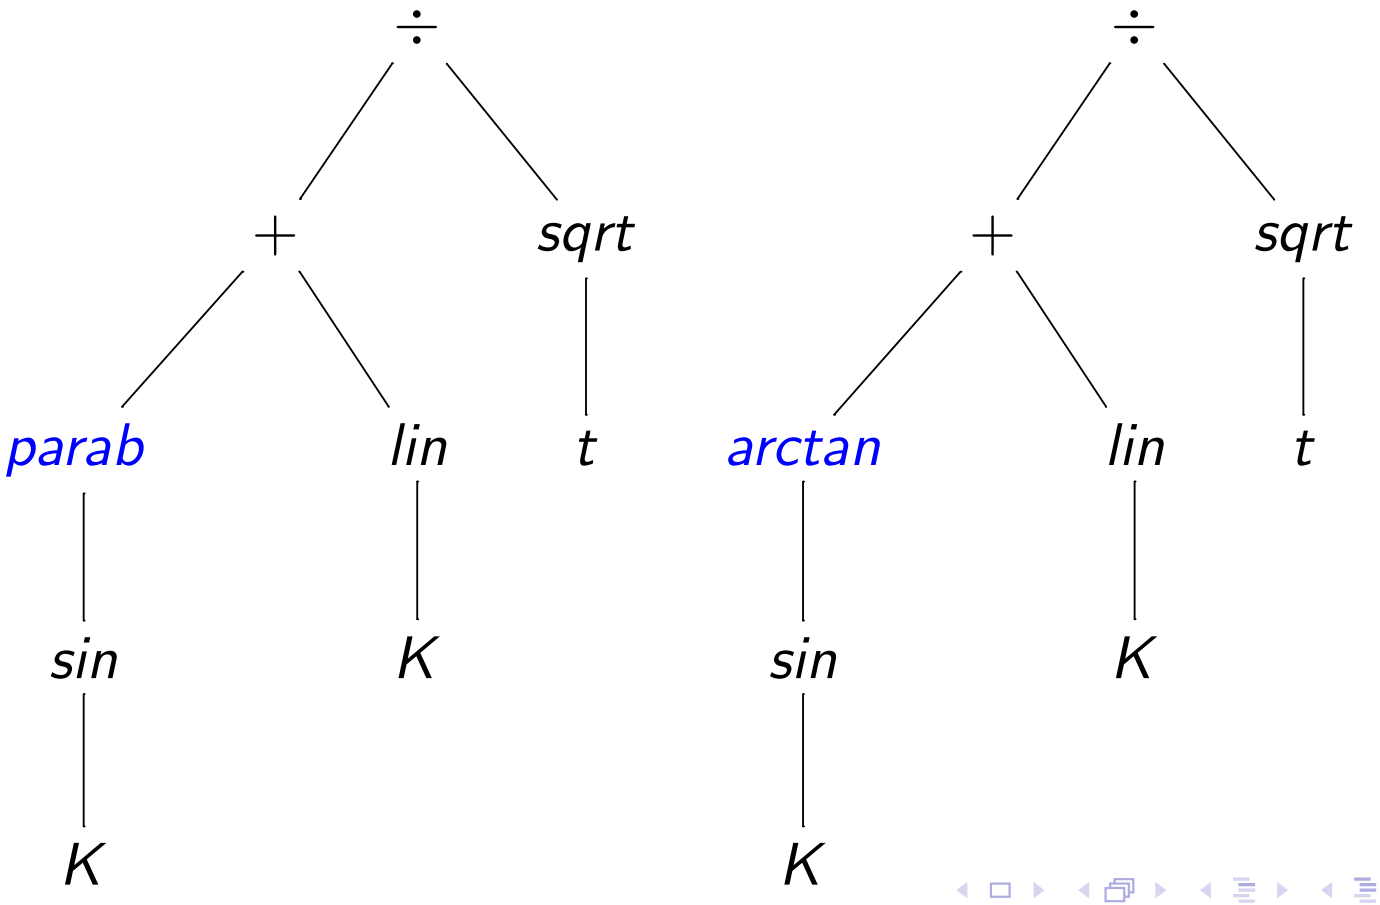
Алгоритм последовательного порождения моделей

1. Выполняется обмен поддеревьями:
   1. случайно выбирается пара суперпозиций f_i и f_j.
   2. в деревьях Γ_i и Γ_j выбираются вершины v_i и v_j
   3. порождаются новые модели f_i' и f_j' путем обмена поддеревьями с корнями в выбранных вершинах.



Алгоритм последовательного порождения моделей

2. Выполняется модификация полученных моделей.
   1. В дереве Γ_j выбирается вершина v_k;
   2. Из элементов G, имеющих число аргументов, как у g_k, выбирается g_s.
   3. Порождающая функция g_k заменяется функцией g_s.



Теорема схем (1975)

Определение

Набор претендентов - множество векторов заданной длины, состоящих из 0 и 1.

Определение

Схемой называется подмножество множества всех возможных векторов с фиксированными значениями некоторых элементов.

Определение

Функция ошибки схемы — это среднее значение функции ошибки всех векторов, её содержащих.

Пример схемы: $**0**11$. Её содержат вектора $1000111, 0001111, 0101011$.

Теорема схем (1975)

Theorem

Количество элементов $N(h,t)$, содержащих схему h на каждой итерации t алгоритма подчиняется неравенству

$$N(h,t+1) \geq N(h,t)\frac{\hat{S}(t)}{\hat{S}(h,t)}[1-p],$$

где p является вероятностью исчезновения схемы при операции обмена поддеревьями.

Если значение $\frac{S(t)}{S(h,t)}[1-p]$ больше 1, наблюдается экспоненциальный рост числа моделей, содержащих h.

Схема и гиперсхема для графового представления

Определение

Схемой называется дерево, содержащее функции из множества $G \bigcup \{=\}$ *и свободные переменные из множества* $T \bigcup \{=\}$, *где* G *и* T — *множества порождающийх функций и свободных переменных соответственно. Порождющая функция* $\{=\}$ *означает произвольный символ, который может быть любой функцией или свободной переменной. Порядком схемы* $O(H)$ *называется количество вершин в ней, не являющихся* $\{=\}$.

Определение

Гиперсхемой называется дерево, содержащее функции из множества $G \bigcup \{=\}$ *и свободные переменные из множества* $T \bigcup \{=, \#\}$. *Порождющая функция* $\{=\}$ *определяется также, как и для схемы, а свободная переменная* $\{\#\}$ *означает любое допустимое дерево.*

Замена поддерева с сохранением структуры

Определение

Операция замены поддерева, для которой топологическая структура родительских вершин заменяемого и заменяющего поддерева равны, будет называться операцией замены поддерева с сохранением структуры. Вводится функция $C(d, i, \Gamma_1, \Gamma_2)$, значение которой равно 1 если условие арности вершин выполняется, и 0 если нет.

Таким образом, $C(d, i, \Gamma_1, \Gamma_2) = 1$, если $(d, i) = (0, 0)$ или

$$A(parent(d, i), \Gamma_1) = A(parent(d, i), \Gamma_2) \neq 0$$
$$A(d, i, \Gamma_1) \geq 0, A(d, i, \Gamma_2) \geq 0,$$
$$C(parent(d, i), \Gamma_1, \Gamma_2) = 1$$

Теорема схем для графового представления

Для операции замены поддерева с сохранением структуры возможно рассчитать вероятность сохранения схемы H:

$$\alpha(H,t) = (1 - p_{x0})p(H,t) + p_{x0}\alpha_{x0}(H,t)$$

где

$$\alpha_{x0}(H,t) = \sum_{h_1}\sum_{h_2}\frac{p(h_1,t)p(h_2,t)}{NC(h_1,h_2)}\sum_{i\in C(h_1,h_2)}\delta(h_1 \in U(H,i))\delta(h_2 \in L(H,i))$$

при этом

- p_{x0} — вероятность замены
- $p(H,t)$ — вероятность выбора вершины из схемы H
- суммы проходят по всем деревьям из набора
- $NC(h_1,h_2)$ — количество вершин с равной структурой родительских вершин.
- $L(H,i)$ — гиперсхема, получаемая из H заменой всех вершин от корня до i на $=$, а всех поддеревьев на $\#$.
- $U(H,i)$ — гиперсхема, получаемая из H заменой поддеревьев ниже i на $\#$.

Эквивалентность моделей

Определение

Модель f_2 с вектором параметров $\mathbf{w}_2$ называется обобщающей для модели f_1 с вектором параметров $\mathbf{w}_1$, если для любого вектора $\mathbf{w}_1$ найдется такой вектор $\mathbf{w}_2$, что для любого $\mathbf{x} \in D$ значения функций $f_1(\mathbf{w}_1, \mathbf{x})$ и $f_2(\mathbf{w}_2, \mathbf{x})$ равны:

$$\mathbf{x} \in D \Rightarrow f_1(\mathbf{w}_1, \mathbf{x}) = f_2(\mathbf{w}_2, \mathbf{x})$$

Определение

Модели f_1 и f_2 с векторами параметров $\mathbf{w}_1$ и $\mathbf{w}_2$ называются эквивалентными, если каждая из них является обобщающей для другой.

Правило замены подграфов

Для упрощения графа необходимо ввести понятие правила замены подграфа.

Определение

Подграф L, удаляемый из графа G в процессе упрощения, будет называться заменяемым подграфом.

Определение

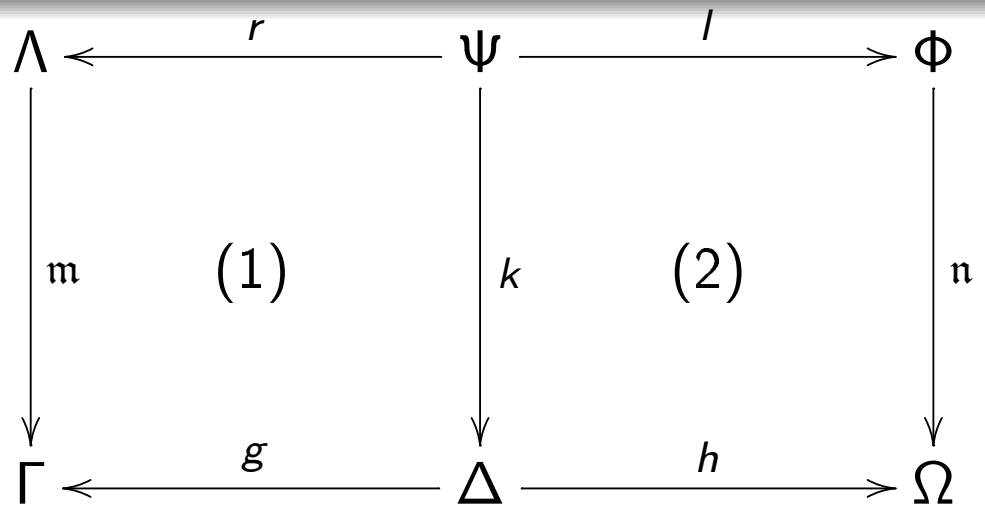
Создаваемый подграф R, помещаемый в граф G в процессе упрощения, будет называться замещающим подграфом.

Категория трансформаций графов

Трансформации графов являются категорией на множестве графов.

- Классом объектов категории является множество графов.
- Стрелками в данной категории являются трансформации графов.
- Тождественным морфизмом является трансформация графа с пустыми подграфами L и R.

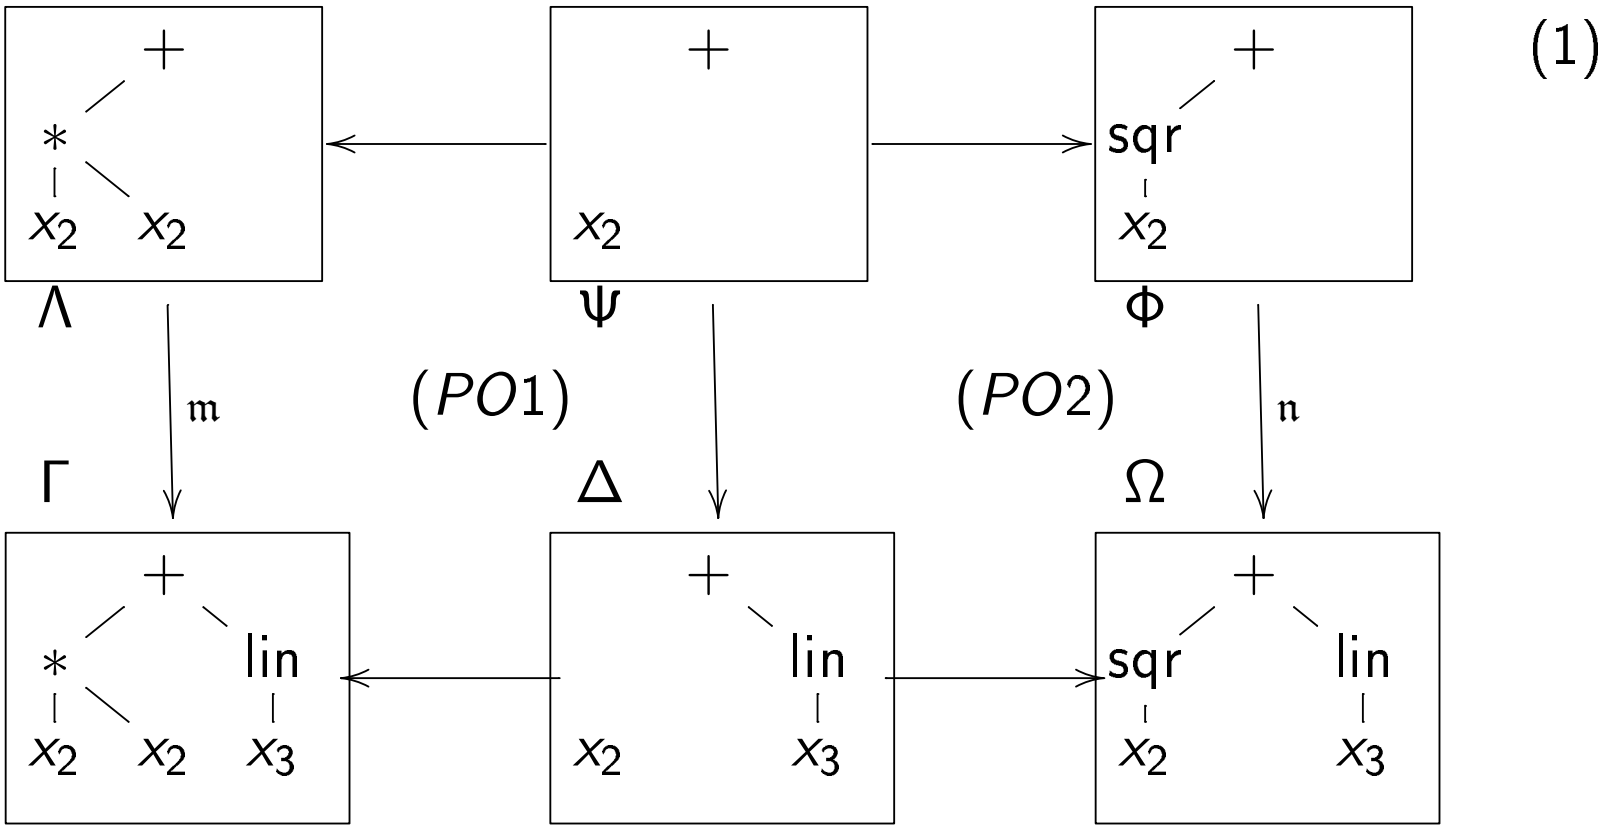
Правило замены подграфов двойным декаторвым квадратом



Определение

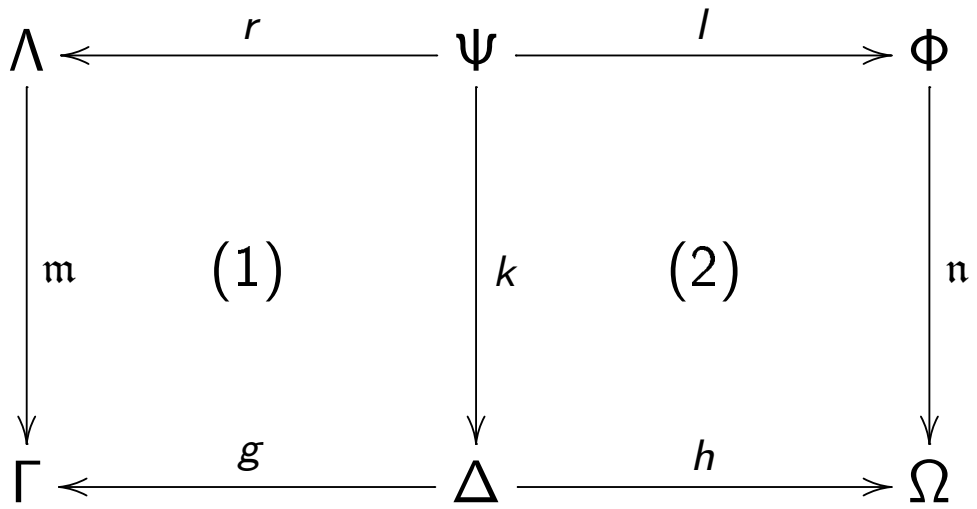
Правило — это тройка $p = (\Lambda, \Psi, \Phi)$, *где* Λ *и* Φ *являются заменяемым и замещающим подграфами. Подграф* Ψ *описывает часть графа, необходимую для применения правила, но неизменную в процессе применения. Множество* $\Lambda \setminus \Psi$ *— удаляемая часть графа, вместо неё создается множество* $\Phi \setminus \Psi$. *Процедура поиска* $\mathfrak{m} : \Lambda \to \Gamma$ *ставит в соответствие заменяемому графу эквивалентный ему подграф.*

Пример трансформации графа



(1)

Условие соединения графов



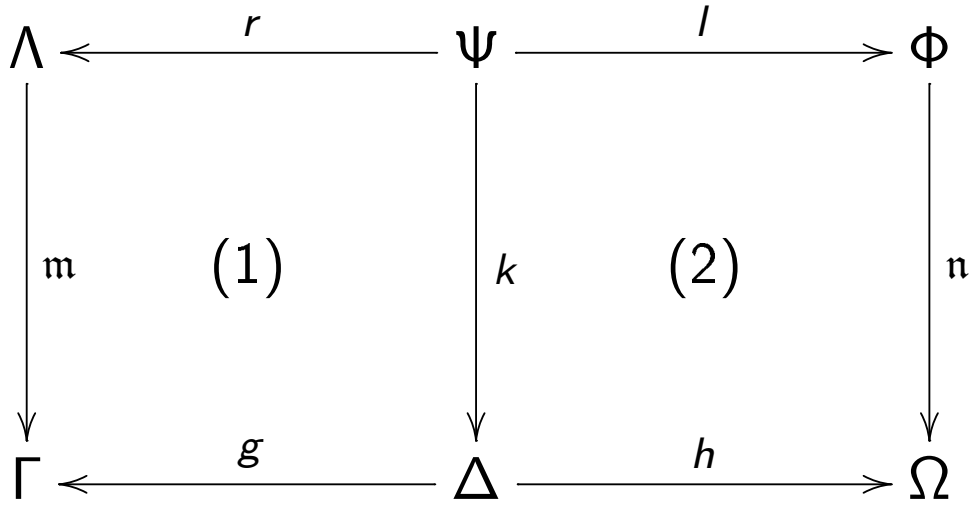
Определение

Точки соединения — вершины и ребра в Λ, которые не удаляются при применении правила p.

Определение

Подвешенные вершины — вершины в Λ, образы которых относительно $\mathfrak{m}$ в Γ имеют входящие или выходящие ребра, не содержащиеся в Λ.

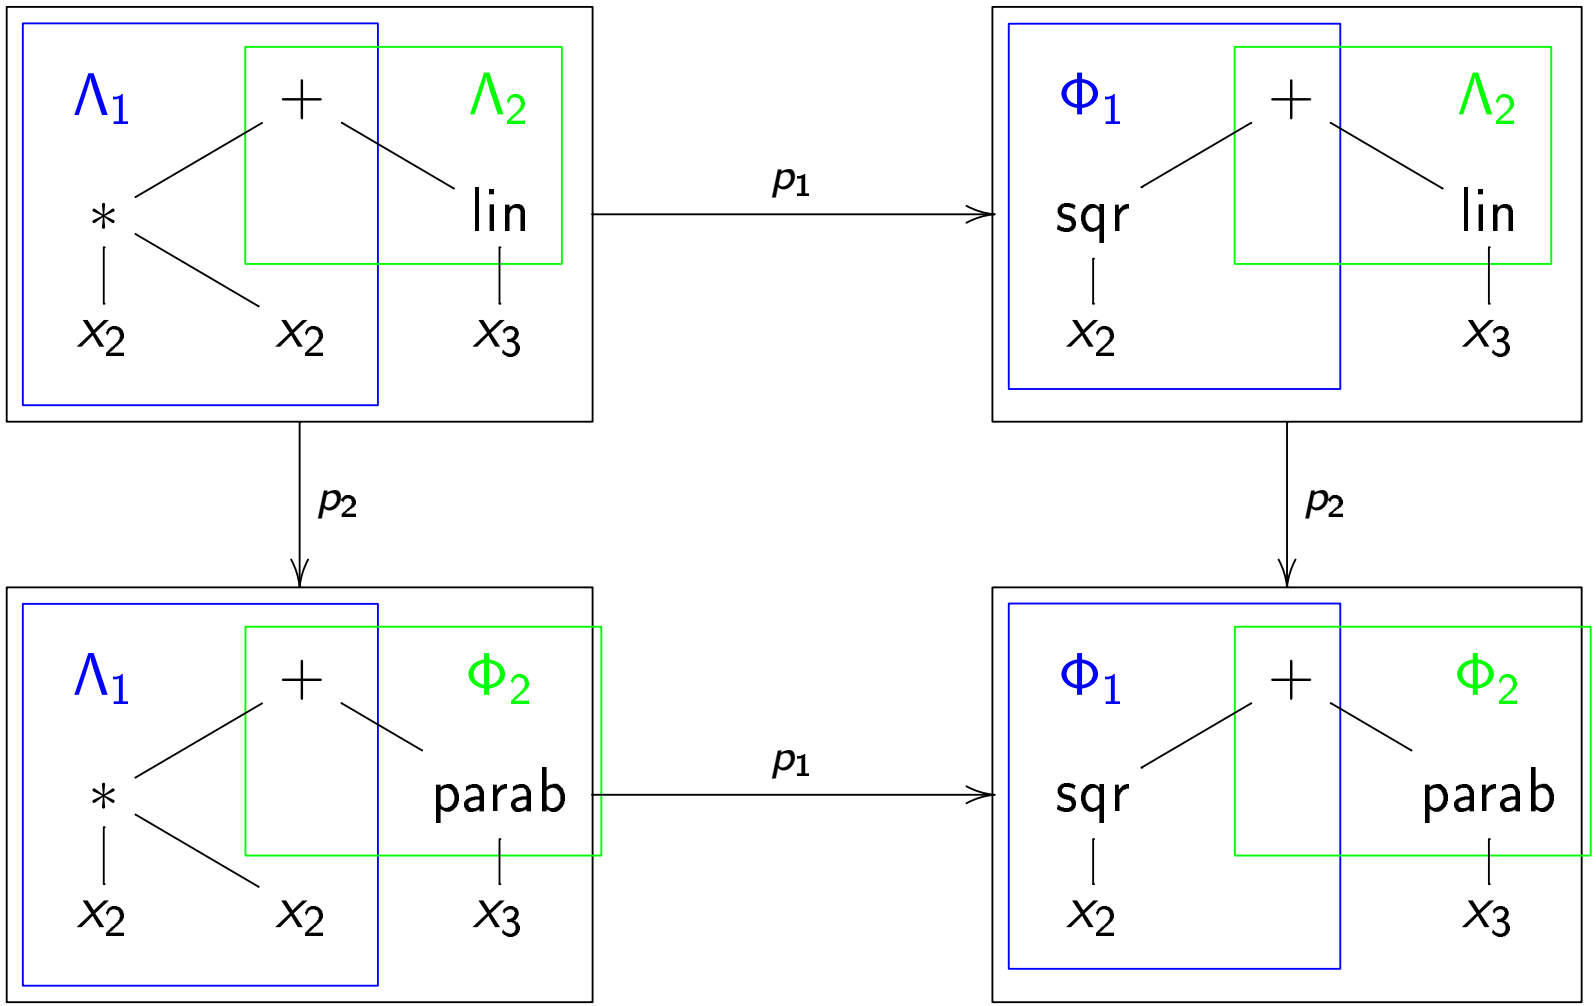
Теорема о применимости правила



Theorem

Пусть дано правило $p = (\Lambda \leftarrow \Psi \rightarrow \Phi)$, *граф* Γ *и процедура поиска* $\mathfrak{m} : \Lambda \rightarrow \Gamma$. *Тогда правило* p *с процедурой поиска* $\mathfrak{m}$ *удовлетворяет условию соединения если все подвешенные вершины являются точками соединения.*

Параллельная и последовательная независимость трансформаций



Параллельная и последовательная независимость трансформаций

Определение

Две трансформации графов $\Gamma \overset{p_1,m_1}{\to} \Omega_1$ *и* $\Gamma \overset{p_2,m_2}{\to} \Omega_2$ *являются параллельно независимыми, если все вершины и ребра, попадающие в образ обоих морфизмов поиска, являются соединительными:*

$$\mathfrak{m}_1(\Lambda_1) \bigcap \mathfrak{m}_2(\Lambda_2) \subseteq \mathfrak{m}_1(l_1(\Psi_1)) \bigcap \mathfrak{m}_2(l_1(\Psi_2))$$

Определение

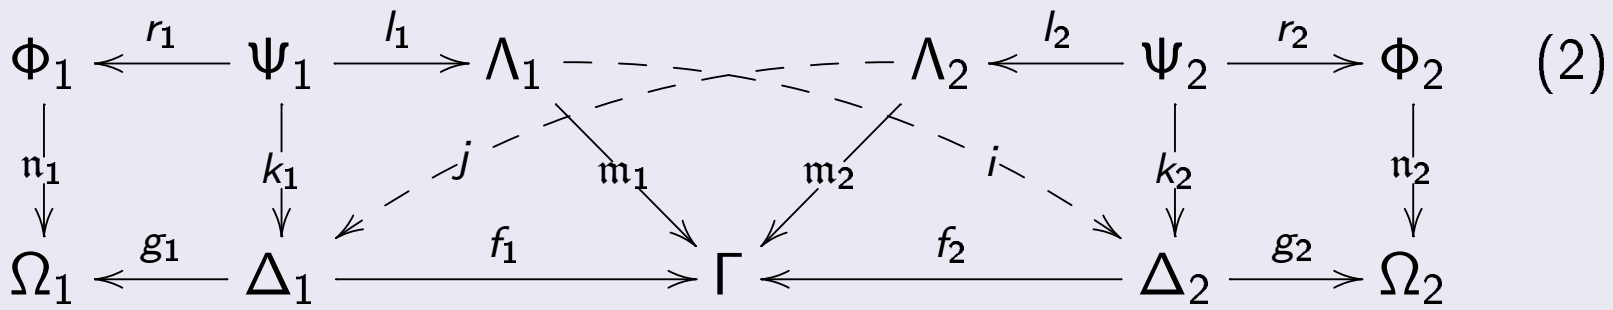
Две трансформации графов $\Gamma \overset{p_1,m_1}{\to} \Omega_1$ *и* $\Omega_1 \overset{p_2,m_2}{\to} \Omega_2$ *являются последовательно независимыми, если все вершины и ребра, попадающие в пересечение морфизмов* $\mathfrak{n}_1$ *и* m_2*, являются соединительными:*

$$\mathfrak{n}_1(\Phi_1) \bigcap \mathfrak{m}_2(\Lambda_2) \subseteq \mathfrak{n}_1(r_1(\Psi_1)) \bigcap \mathfrak{m}_2(l_2(\Psi_2))$$

Критерий параллельной независимости

Theorem

Две трансформации графов $\Gamma \overset{p_1, m_1}{\Rightarrow} \Omega_1$ *и* $\Gamma \overset{p_2, m_2}{\Rightarrow} \Omega_2$ *являются параллельно независимыми, если существуют морфизмы* $i : \Lambda_1 \to \Delta_2$ *и* $j : \Lambda_2 \to \Delta_1$, *такие что* $f_2 \circ i = \mathfrak{m}_1$ *и* $f_1 \circ j = \mathfrak{m}_2$*:*

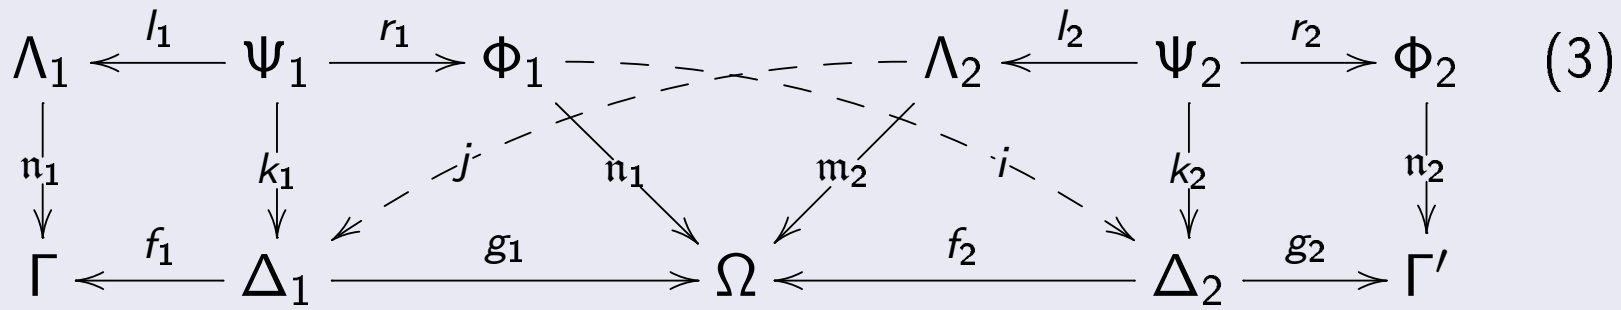


(2)

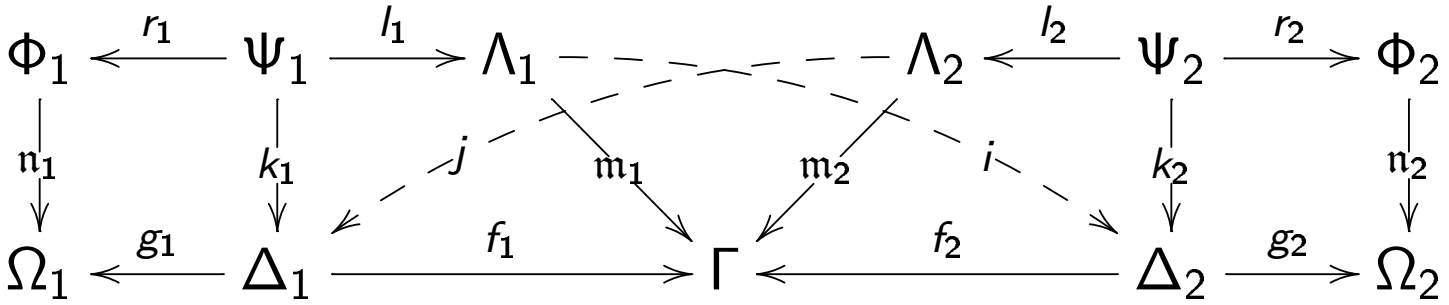
Критерий последовательной независимости

Theorem

Две трансформации графов $\Gamma \overset{p_1, m_1}{\Rightarrow} \Omega$ *и* $\Omega \overset{p_2, m_2}{\Rightarrow} \Gamma'$ *являются последовательно независимыми, если существуют морфизмы* $i : \Phi_1 \to \Delta_2$ *и* $j : \Lambda_2 \to \Delta_1$, *такие что* $f_2 \circ i = \mathfrak{n}_1$ *и* $g_1 \circ j = \mathfrak{m}_2$*:*



Доказательство критерия параллельной независимости

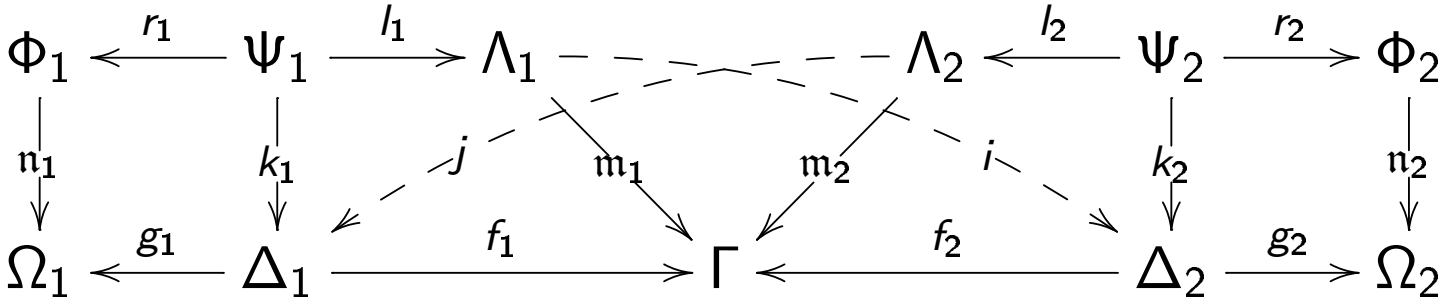


Рассмотрим варианты принадлежности $\mathfrak{m}_1(v)$.

1. Множество $\mathfrak{m}_1(v) \notin \mathfrak{m}_2(\Lambda_2)$. Все вершины графа Γ являются образами при применении отображений $\mathfrak{m}_2$ или f_2. Отсюда $\mathfrak{m}_1(v) \in f_2(\Delta_2)$.
2. Множество $\mathfrak{m}_1(v) \in \mathfrak{m}_2(\Lambda_2)$. Тогда $\mathfrak{m}_1(v) \in \mathfrak{m}_1(\Lambda_1) \cap \mathfrak{m}_2(\Lambda_2) \subseteq \mathfrak{m}_1(l_1(\Psi_1)) \cap \mathfrak{m}_2(l_2(\Psi_2))$. При этом из коммутативной диаграммы следует, что $\mathfrak{m}_2(l_2(\Psi_2)) = f_2(k_2(\Psi_2))$. Отсюда $\mathfrak{m}_1(v) \in f_2(\Delta_2)$.

В обоих случаях $\mathfrak{m}_1(x) \in f_2(\Delta_2)$, из инъективности f_2: $i(x) = f_2^{-1} \circ \mathfrak{m}_1(x)$. Аналогично, j из условия $f_1 \circ j = \mathfrak{m}_2$.

Доказательство критерия параллельной независимости



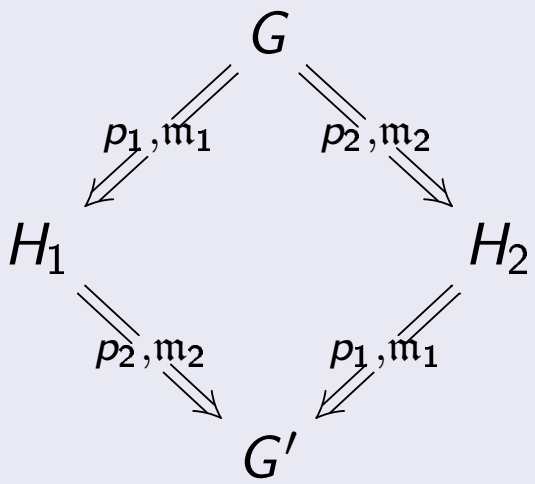
При данных i, j с $f_2 \circ i = m_1$ и $f_1 \circ j = m_2$, пусть $y \in \mathfrak{m}_1(\Lambda_1) \bigcap \mathfrak{m}_2(\Lambda_2)$. Тогда $y \in \mathfrak{m}_1(\Lambda_1) \bigcap f_1(j(\Lambda_2))$. Из условия кодекартова квадрата следует, что существует $z_1 \in \Psi_1$, такое что $y = \mathfrak{m}_1(l_1(z_1)) = f_1(k_1(z_1))$. Значит $y \in \mathfrak{m}_1(l_1(\Psi_1))$, аналогично $y \in \mathfrak{m}_2(l_2(\Psi_2))$, откуда следует условие независимости $\mathfrak{m}_1(\Lambda_1) \bigcap \mathfrak{m}_2(\Lambda_2) \subseteq \mathfrak{m}_1(l_1(\Psi_1)) \bigcap \mathfrak{m}_2(l_1(\Psi_2))$.

Теорема Чёрча-Россера

Theorem

Пусть даны две параллельно независимых трансформации графов $\Gamma \overset{p_1,m_1}{\to} \Omega_1$ *и* $\Gamma \overset{p_2,m_2}{\to} \Omega_2$. *Тогда существует граф* Γ', *такой что* $\Omega_1 \overset{p_2,m_2}{\to} \Gamma'$ *и* $\Omega_2 \overset{p_1,m_1}{\to} \Gamma'$, *а пары трансформаций* $\Gamma \overset{p_1,m_1}{\to} \Omega_1$, $\Omega_1 \overset{p_2,m_2}{\to} \Gamma'$ *и* $\Gamma \overset{p_2,m_2}{\to} \Omega_2, \Omega_2 \overset{p_1,m_1}{\to} \Gamma'$ *последовательно независимы.*

Пусть даны последовательно независимые трансформации $\Gamma \overset{p_1,m_1}{\to} \Omega_1$ *и* $\Omega_1 \overset{p_2,m_2}{\to} \Gamma'$. *Тогда существует граф* Ω_2 *такой что* $\Gamma \overset{p_2,m_2}{\to} \Omega_2$ *и* $\Omega_2 \overset{p_1,m_1}{\to} \Gamma'$, *а трансформации* $\Gamma \overset{p_1,m_1}{\to} \Omega_1$ *и* $\Gamma \overset{p_2,m_2}{\to} \Omega_2$ *параллельно независимы.*



Трансформации элементов графов

Трансформации графов — операции с двумя базовыми множествами V (вершины) и E (ребра) и операциями $s : E \to V$(источник) и $t : E \to V$ (цель). Морфизмы f:

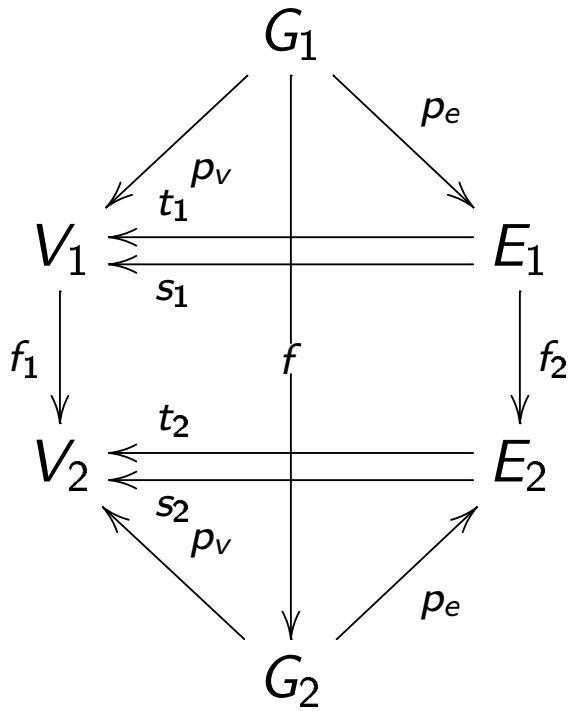
$$f : \Gamma_1 \to \Gamma_2$$

являются частными случаями гомоморфизмов общего вида:

$$f = (f_V : V_1 \to V_2, f_E : E_1 \to E_2).$$

Это значит, что f_V и f_E должны быть совместимы с операциями s и t, т.е.

$$f_V \circ s_1 = s_2 \circ f_E \text{ и } f_V \circ t_1 = t_2 \circ f_E$$



Прикладное упрощение моделей

Определение

Шаблон θ — гиперсхема с наименьшей сложностью среди всех гиперсхем, при взаимном замещении которых получаемые модели эквивалентны. Сложность гиперсхемы определяется как сложность суперпозиции при замещении всех символов $\{=\}$ и $\{\#\}$ на константы.

Экспертно выбирается некоторый набор шаблонов Θ.

Процедура упрощения состоит из двух шагов:

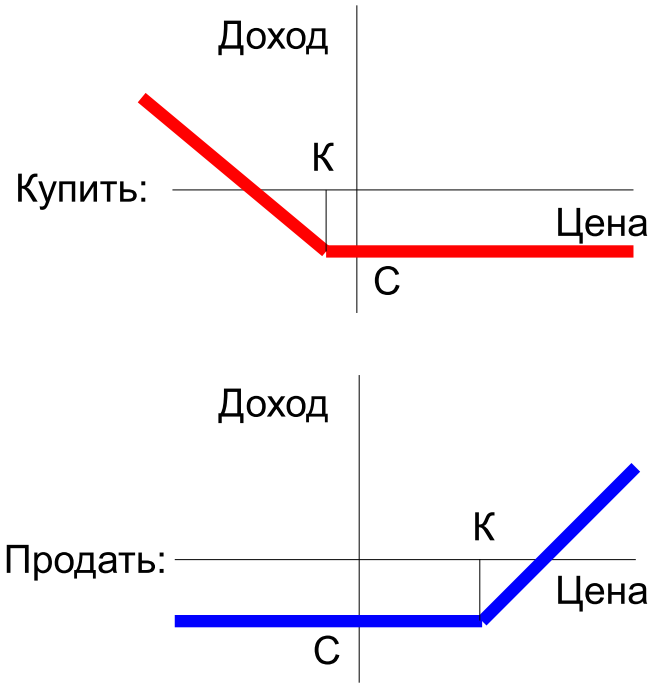
1. Все поддеревья Γ_j в выбранном дереве Γ проверяются на эквивалентность шаблонам из Θ согласно заданным правилам.
2. Если какое-либо поддерево Γ_j в дереве эквивалентно дереву из Θ, данное поддерево заменяется соответствующим элементом из Θ.

Построение модели волатильности опционов

Опцион — контракт, дающий покупателю право покупки или продажи актива по заданной цене в заданный момент времени.

$$C_t = F(\sigma, P, B, K, t),$$

C_t — цена опциона,
σ — волатильность,
P — цена базового актива,
B — безрисковая ставка,
K — цена исполнения опциона,
t — время до исполнения.



$$C_T = \Phi\left(\frac{ln(\frac{P}{K}) + T(B + \frac{\sigma^2}{2})}{\sigma\sqrt{T}}\right) - Ke^{-BT}\Phi\left(\frac{ln(\frac{P}{K}) + T(B - \frac{\sigma^2}{2})}{\sigma\sqrt{T}}\right),$$

Историческая цена актива

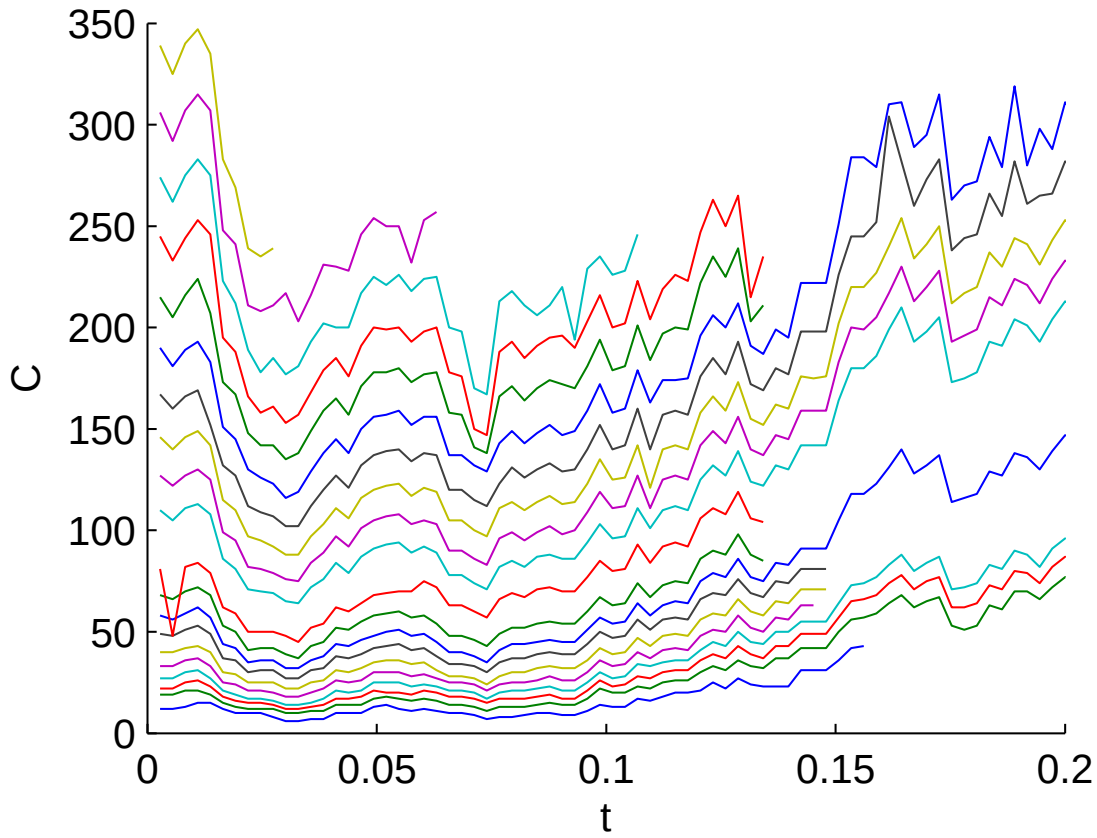


t – время до исполнения опциона в годах,

P — цена актива в указанный период.

Горизонтальные линии соответствуют различным ценам исполнения K.

Исторические цены опционов для всех K



t — время до исполнения опциона в годах,

C — цена опциона в указанный период.

Вычисление волатильности опциона

Волатильность — характеристика изменчивости цены базового актива,

$$\sigma^{\text{imp}} = \arg\min_{\sigma}(C_{\text{hist}} - C(\sigma, P, B, K, t)).$$

Предполагаемая волатильность — зависимая переменная искомой регрессионной модели, зависящая от времени t и цены исполнения K.





Модель волатильности, предложенная экспертами

Модель для игроков рынка РТС

$$\sigma = \sigma(\mathbf{w}) = w_1 + w_2(1 - \exp(-w_3 x^2)) + \frac{w_4 \arctan(w_5 x)}{w_5},$$

$$\text{где} \quad x = \frac{\log(K) - \log(C(t))}{\sqrt{t}}.$$

Модельные предположения [Дэглиш, 2006]

- Волатильность зависит зависит только от цены опциона:

$$\frac{d\sigma}{dP} = \frac{\partial\sigma}{\partial C(P)} \frac{dC(P)}{dP}.$$

- Волатильность зависит от времени пропорционально обратному корню:

$$\sigma = \Phi\left(\frac{ln(K/F)}{\sqrt{t}}\right).$$

Исторические данные

- В работе использовались следующие данные:
  - Полугодовой опцион Brent Crude Oil, с 02.01.2001 по 26.06.2001. Тип опциона — put, символ CLZ01.
  - Квартальный опцион CNX 100, индекс рынка Дели, с 30.09.2007 по 27.12.2007. Тип опциона — call, символ CE.
- Модель начального приближения предложена экспертами РТС

$$\sigma = \sigma(\mathbf{w}) = w_1 + w_2(1 - \exp(-w_3 x^2)) + \frac{w_4 \arctan(w_5 x)}{w_5},$$

где $x = \frac{\ln K - \ln C(t)}{\sqrt{t}}$.

Исходные данные

Время	K1	K2	K3	K4	K5	K6	**Цена**
-91	0.105	0.16	0.24	0.36	0.56	0.725	**11.27**
-90	0.105	0.16	0.24	0.35	0.56	0.725	**11.29**
-87	0.105	0.16	0.21	0.36	0.56	0.725	**11.34**
-86	0.105	0.16	0.21	0.32	0.56	0.725	**11.2**
-85	0.105	0.16	0.21	0.32	0.48	0.725	**11.18**
-84	0.105	0.16	0.215	0.33	0.625	0.725	**11.5**
...	...	...	...	...	...	...	...

Данные для задачи регрессии формируются следующим образом:

$$\sigma_{t,K} \to \sigma_i, i = \tau + k(|\mathbf{T}| - 1)$$

$$(t_i, K_i) \in \mathbf{T} \times \mathbf{K}$$

Регрессионная модель

$$\sigma_i, i = f(t_i, K_i)$$

Порождающие функции

Функция	Описание	Параметры
	$g(\mathbf{w}, x_1, x_2)$	
plus2	$y = x_1 + x_2$	–
times2	$y = x_1 x_2$	–
frac2	$y = x_1 / x_2$	–
	$g(\mathbf{w}, x)$	
inv	$y = 1/x$	–
add	$y = x + a$	a
normalpdf	$y = \frac{\lambda}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\xi)^2}{2\sigma^2}\right) + a$	λ, σ, ξ, a
linear	$y = ax + b$	a, b
parabolic	$y = ax^2 + bx + c$	a, b, c
sqrt	$y = \sqrt{x}$	–
arctan	$y = \arctan(ax)$	a

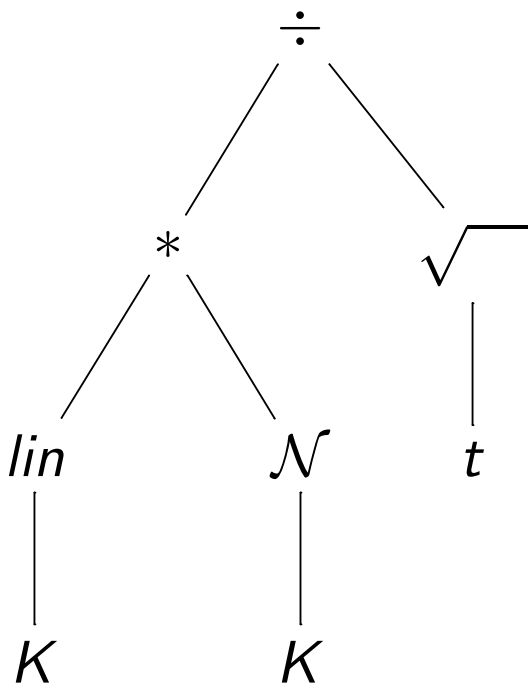
Результаты для опциона CNX 100

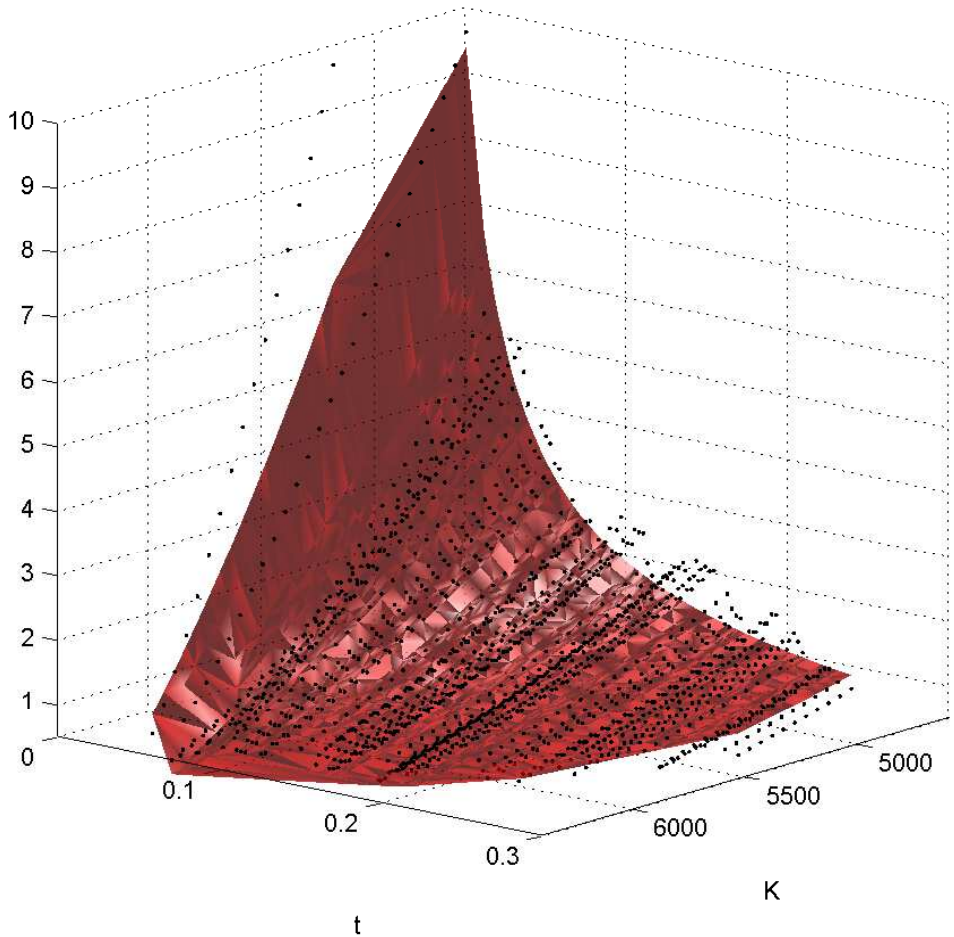
Проведено 5 запусков программы на исходных данных, по которым сгенерировано более 15000 моделей. Среди 200 лучших:

- Обратно корневая зависимость от времени наблюдается более чем у 160 лучших моделей.
- Зависимость от цены исполнения более чем у 140 лучших моделей полиномиальная.

Результаты для опциона CNX 100

$$\sigma = \frac{(w_1 K + w_2)\mathcal{N}(K, w_3)}{\sqrt{t}}$$





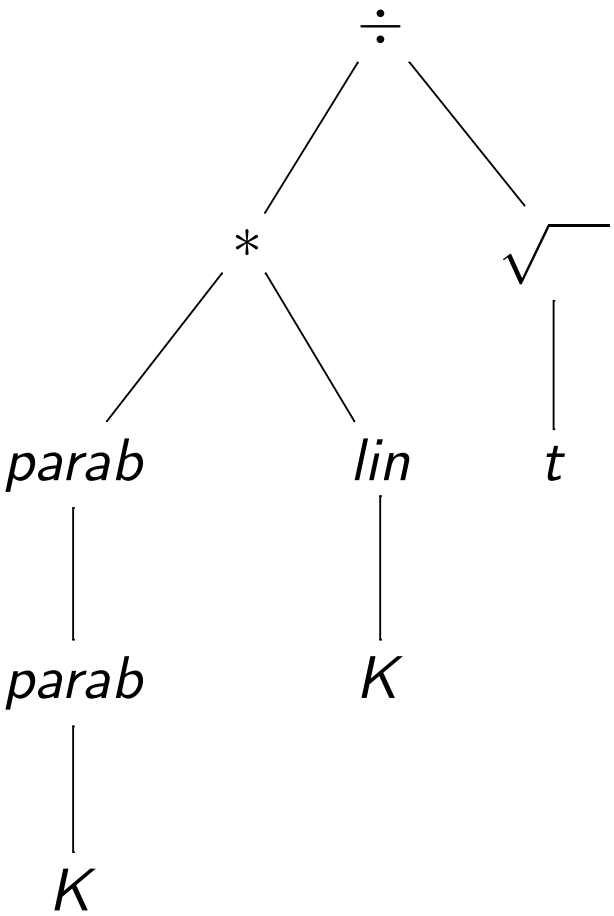
Результаты для опциона CLZ

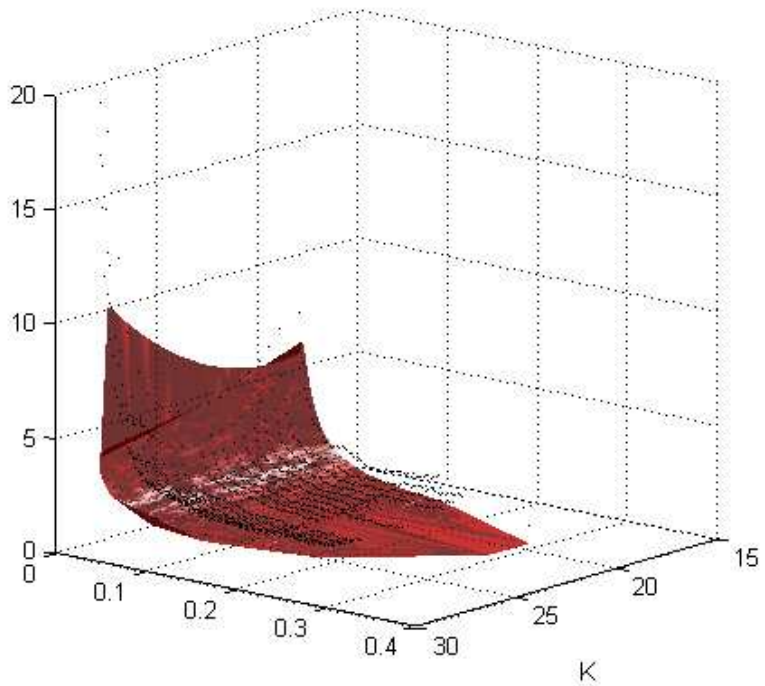
Проведено 10 запусков программы на исходных данных, по которым сгенерировано более 25000 моделей. Среди 400 лучших:

- Обратно корневая зависимость от времени наблюдается более чем у 300 лучших моделей.
- Зависимость от цены исполнения более чем у 250 лучших моделей полиномиальна.

Результаты для опциона CLZ

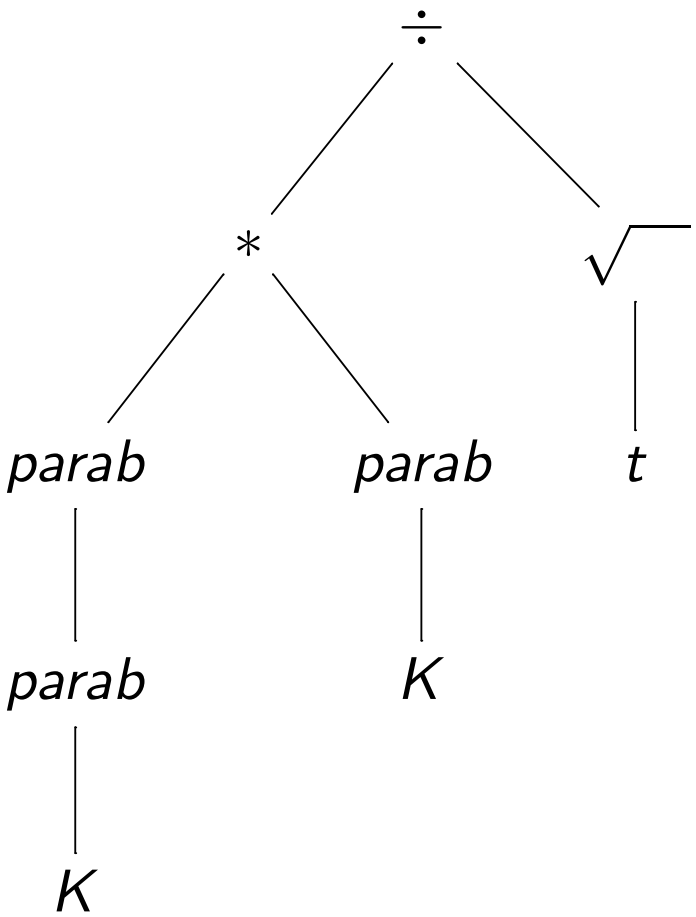
$$\sigma = \frac{(w_1 K + w_2)(w_1 K^2 + w_2 K + w_3)}{\sqrt{t}}$$

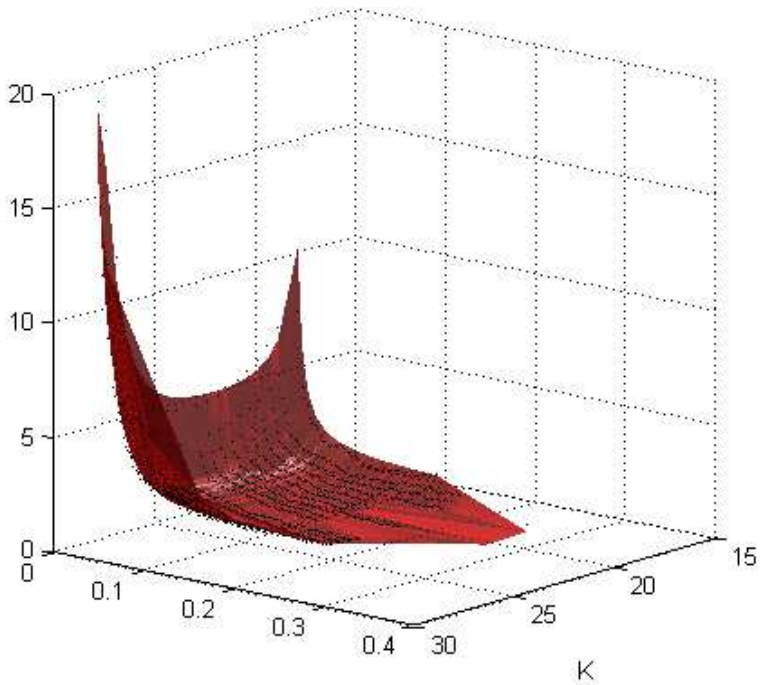




Результаты для опциона CLZ

$$\sigma = \frac{(w_1 K + w_2)(w_1 K^2 + w_2 K + w_3)^2}{\sqrt{t}}$$





Результаты вычислительного эксперимента

1. Получена применимая модель волатильности, интерпретируемая экспертами.
2. Зависимость волатильности от времени обратно-корневая.
3. Зависимость волатильности от цены исполнения полиномиальная.
4. В случае, когда волатильность слабо зависит от цены исполнения, итоговая модель зависит только от времени (согласно модели Блэка-Шоулза).
5. Цена актива как переменная практически не встречается в лучших моделях, в случае её задания как независимой переменной.

Заключение

1. Исследованы различные функции, описывающие расстояния и сложности порождаемых регрессионных моделей.
2. Рассмотрена теорема схем в приложении к моделям, представленным в виде деревьев.
3. Формально описаны операции, модифицирующие модели.
4. Разработан алгоритм порождения регрессионных моделей, интерпретируемых экспертами в контексте предметной области.
5. Получено подтверждение гипотез Даглиша-Халла-Суо построения поверхностей волатильности.